

## 6. Inference for regression parameters and models

对回归参数  $\beta \in \mathbb{R}^p$  的检验：

$$H_0: A\beta = u \quad v.s. \quad H_1: A\beta \neq u$$

其中常数矩阵  $A \in \mathbb{R}^{m \times p}$   $\text{rank}(A) = m$ ，常数向量  $u \in \mathbb{R}^m$

Tips：通过设置  $A$  的每一行只有一个元素为 1，其他为 0，再令  $u=0$  可以检验  $\beta$  的某些分量是否为 0（ $A$  第一列为 0，因为不检验截距项）

e.g.  $p=3$  时，令  $A = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$   $u=0 \Rightarrow \beta_2 = \beta_3 = 0$

Lemma 1 矩阵  $D = A(X^T X)^{-1} A^T$  正定  $A \in \mathbb{R}^{m \times p}$   $\text{rank}(A) = m$

Proof  $v^T D v = (A^T v)(X^T X)^{-1}(A^T v) \geq 0$  ( $(X^T X)^{-1}$  正定)  $\Rightarrow$  只须证  $A^T v \neq 0, v \neq 0$

$$V = \{v : A^T v = 0\} \quad \text{rank}(A^T) + \dim(V) = m \Rightarrow \dim(V) = 0 \Rightarrow V = \{0\}, A^T v \neq 0$$

## 6.1 CLSE 约束的最小二乘估计 (Constrained least squares estimation)

假设检验： $H_0$  成立，寻找反常事件，故要引入  $H_0$  的条件

Definition 1 我们称满足：

$$\hat{\beta}_c = \underset{b}{\arg \min} \|y - Xb\|^2$$

$$\text{s.t. } \begin{cases} Ab = u \\ b \in \mathbb{R}^p \end{cases}$$

的  $\hat{\beta}_c$  为“满足  $Ab = u$  的约束最小二乘估计”，其解析解为

$$\hat{\beta}_c = \hat{\beta} - (X^T X)^{-1} A^T D^{-1} (A\hat{\beta} - u)$$

其中  $D = A(X^T X)^{-1} A^T$  正定， $\hat{\beta}$  是 OLS 为  $\hat{\beta} = (X^T X)^{-1} X^T y$

Proof: (Lagrange) 构造:  $F(b, \lambda) = \|y - Xb\|^2 + 2\lambda^T(Ab - u)$

其中  $\lambda \in \mathbb{R}^m, A \in \mathbb{R}^{m \times p}, b \in \mathbb{R}^p, u \in \mathbb{R}^m, X \in \mathbb{R}^{m \times p}, y \in \mathbb{R}^m$

$$\text{求导 } \frac{\partial F}{\partial b} \Big|_{b=\hat{\beta}_c, \lambda=\hat{\lambda}_c} = -2X^T(y - X\hat{\beta}_c) + 2A^T\hat{\lambda}_c = 0$$

$$\text{求导 } \frac{\partial F}{\partial \lambda} \Big|_{b=\hat{\beta}_c, \lambda=\hat{\lambda}_c} = A\hat{\beta}_c - u = 0$$

$$\text{故: } \hat{\beta}_c = (X^T X)^{-1} X^T y - (X^T X)^{-1} A^T \hat{\lambda}_c = \hat{\beta} - (X^T X)^{-1} A^T \hat{\lambda}_c$$

$$\therefore u = A\hat{\beta}_c = A\hat{\beta} - A(X^T X)^{-1} A^T \hat{\lambda}_c = A\hat{\beta} - D\hat{\lambda}_c$$

$$\therefore \hat{\lambda}_c = D^{-1}(A\hat{\beta} - u) \text{ 代入 } \hat{\beta}_c \text{ 有}$$

$$\hat{\beta}_c = \hat{\beta} - (X^T X)^{-1} A^T D^{-1}(A\hat{\beta} - u)$$

下面证明唯一性:

Theorem 1  $\hat{\beta}_c = \hat{\beta} - (X^T X)^{-1} A^T D^{-1}(A\hat{\beta} - u)$  满足:

$$(a). A\hat{\beta}_c = u$$

$$(b). \text{对 } \forall b \in \mathbb{R}^p, b \neq \hat{\beta}_c, \text{ 满足 } Ab = u, \text{ 均有}$$

$$\|y - Xb\|^2 > \|y - X\hat{\beta}_c\|^2$$

Proof: 对于 (a).  $A\hat{\beta}_c = A\hat{\beta} - A(X^T X)^{-1} A^T D^{-1}(A\hat{\beta} - u)$

$$= A\hat{\beta} - D D^{-1}(A\hat{\beta} - u)$$

$$= A\hat{\beta} - A\hat{\beta} + u$$

$$= u \quad \square$$

对于 (b).

$$\|y - Xb\|^2 = \|y - X\hat{\beta} + X\hat{\beta} - Xb\|^2$$

$$= \|y - X\hat{\beta}\|^2 + \|X\hat{\beta} - Xb\|^2 + 2(y - X\hat{\beta})^T(X\hat{\beta} - Xb)$$

注意:  $(y - X\hat{\beta})^T X = y^T X - \hat{\beta}^T X^T X = y^T X - y^T X(X^T X)^{-1} X^T X = 0$

$$\therefore \text{原式} = \|y - X\hat{\beta}\|^2 + \|X\hat{\beta} - Xb\|^2$$

$$= \|y - X\hat{\beta}\|^2 + \|X(\hat{\beta} - \hat{\beta}_c + \hat{\beta}_c - b)\|^2$$

$$= \|y - X\hat{\beta}\|^2 + \|X(\hat{\beta} - \hat{\beta}_c)\|^2 + \|X(\hat{\beta}_c - b)\|^2 + 2(\hat{\beta} - \hat{\beta}_c)^T X^T X (\hat{\beta}_c - b)$$

注意:  $(\hat{\beta} - \hat{\beta}_c)^T X^T X (\hat{\beta}_c - b) = [(X^T X)^{-1} A^T \hat{\lambda}_c]^T X^T X (\hat{\beta}_c - b)$

$$= \hat{\lambda}_c^T A (X^T X)^{-1} X^T X (\hat{\beta}_c - b) = \hat{\lambda}_c^T A (\hat{\beta}_c - b) = \hat{\lambda}_c^T (u - u) = 0$$

$$\therefore \text{原式} = \|y - X\hat{\beta}\|^2 + \|X(\hat{\beta} - \hat{\beta}_c)\|^2 + \|X(\hat{\beta}_c - b)\|^2$$

即:  $\|y - Xb\|^2 = \|y - X\hat{\beta}\|^2 + \|X(\hat{\beta} - \hat{\beta}_c)\|^2 + \|X(\hat{\beta}_c - b)\|^2 \quad \forall b \in \mathbb{R}^p \quad Ab = u$

取  $b = \hat{\beta}_c$  有:

$$\|y - X\hat{\beta}_c\|^2 = \|y - X\hat{\beta}\|^2 + \|X(\hat{\beta} - \hat{\beta}_c)\|^2$$

于是有:  $\|y - Xb\|^2 - \|y - X\hat{\beta}_c\|^2 = \|X(\hat{\beta}_c - b)\|^2 \geq 0$

取等时:  $X(\hat{\beta}_c - b) = 0 \quad \because \text{rank}(X) = p \quad \therefore \dim(\text{Col}(X)) = p - p = 0$

其中  $\text{Col}(X) = \{v : Xv = 0\} \Rightarrow \hat{\beta}_c - b = 0$  矛盾!

故当  $b \neq \hat{\beta}_c$  时, 有  $\|y - Xb\|^2 - \|y - X\hat{\beta}_c\|^2 > 0 \quad \square$

## 6.2 假设检验

$$\hat{\beta}_c = \hat{\beta} - (X^T X)^{-1} A^T D^{-1} (A \hat{\beta} - u)$$

### (1) SST, SSR 和 SSE

Property

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$SST = SSR + SSE$$

Rm: 证明见第7周作业，核心：

$$\frac{\partial Q}{\partial b} \Big|_{b=\hat{\beta}} = \sum_{i=1}^n x_i e_i = X^T (y - X \hat{\beta}) = 0 \in \mathbb{R}^p$$

利用矩阵形式：

$$SSE = \|y - \hat{y}\|^2 = \|y - X \hat{\beta}\|^2$$

### (2) 约束 $A\beta = u$ 下的 $SSE_c$

$$SSE_c = \|y - X \hat{\beta}_c\|^2$$

### (3) 检验 $H_0$ 的统计量构造： $\frac{SSE}{SSE_c}$

若假设  $H_0$  不成立，则  $A\beta = u$  的约束条件会显著损害拟合效果，

使  $SSE_c$  大于  $SSE$ ，所以自然地我们去检验

$$\frac{SSE}{SSE_c}$$

Theorem 2

添加正态假设  $\varepsilon \sim N(0, \sigma^2 I)$ ，我们有：

Very Important  
**REMINDER**

$$(1) \frac{SSE}{\sigma^2} \sim \chi^2(n-p)$$

$$(2) \text{若 } H_0: A\beta = u \text{ 成立, 则 } \frac{SSE_c - SSE}{\sigma^2} \sim \chi^2(m)$$

$$(3) \text{若 } H_0: A\beta = u \text{ 成立, 则 } SSE \perp SSE_c - SSE$$

(4) 若  $H_0: A\beta = u$  成立, 则

$$\frac{(SSE_c - SSE)/m}{SSE/(n-p)} \sim F(m, n-p)$$

Proof(1)  $SSE = \|y - \hat{y}\|^2 = \|e\|^2 = e^T e$        $\|y - X\hat{\beta}_c\|^2$   
 由作业题:  $\frac{e^T e}{\sigma^2} \sim \chi^2(n-p)$        $= \|y - X\hat{\beta}\|^2 + \|X(\hat{\beta} - \hat{\beta}_c)\|^2$

Proof(2) 由之前的证明唯一性:

$$\|y - X\hat{\beta}_c\|^2 = \|y - X\hat{\beta}\|^2 + \|X(\hat{\beta} - \hat{\beta}_c)\|^2$$

$$\begin{aligned} \therefore SSE_c - SSE &= \|X(\hat{\beta} - \hat{\beta}_c)\|^2 \quad \leftarrow \star \\ &= \|X[\hat{\beta} - (\hat{\beta} - (X^T X)^{-1} A^T D^{-1}(A\hat{\beta} - u)]\|^2 \\ &= \{X(X^T X)^{-1} A^T D^{-1}(A\hat{\beta} - u)\}^T \{X(X^T X)^{-1} A^T D^{-1}(A\hat{\beta} - u)\} \\ &= (A\hat{\beta} - u)^T D^{-1} A (X^T X)^{-1} X^T \cdot X(X^T X)^{-1} A^T D^{-1}(A\hat{\beta} - u) \\ &= (A\hat{\beta} - u)^T D^{-1} A (X^T X)^{-1} A^T D^{-1}(A\hat{\beta} - u) \\ &= (A\hat{\beta} - u)^T D^{-1} D D^{-1}(A\hat{\beta} - u) \\ &= (A\hat{\beta} - u)^T D^{-1}(A\hat{\beta} - u) \end{aligned}$$

$$D = A(X^T X)^{-1} A^T \in \mathbb{R}^{m \times m}$$

$$\therefore \hat{\beta} \sim N(\beta, (X^T X)^{-1} \sigma^2) \Rightarrow (A\hat{\beta} - u) \sim N(A\beta - u, \sigma^2 D) \text{ 而当 } H_0 \text{ 成立时.}$$

$$A\beta - u = 0 \Rightarrow (A\hat{\beta} - u) \sim N(0, \sigma^2 D) \text{ 而 } D \text{ 可逆,}$$

而由 Chapter 4 (Proposition 4) 知

$$\frac{SSE_c - SSE}{\sigma^2} = \left(\frac{A\hat{\beta} - u}{\sigma}\right)^T D^{-1} \left(\frac{A\hat{\beta} - u}{\sigma}\right) \sim \chi^2(m)$$

Proof(3): SSE 是 e 的函数,  $SSE_c - SSE$  是  $\hat{\beta}$  的函数.

$$\text{而 } \hat{\beta} \perp e \Rightarrow SSE \perp SSE_c - SSE$$

Proof(4): 由 F-distribution 定义可知:

$$Rm: \hat{\sigma}^2 = \frac{SSE}{n-p} = \frac{e^T e}{n-p} = \frac{1}{n-p} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Remark:

若  $H_0: A\beta = u$  成立，则

$$\frac{(A\hat{\beta} - u)^T D^{-1} (A\hat{\beta} - u) / m}{SSE / (n-p)} \sim F(m, n-p)$$

(4) 特例：对单个  $\beta_j$  检验  $\xrightarrow{m=1}$

令  $A = [0, 0, \dots, 1, \dots, 0, 0]^T \in \mathbb{R}^{n \times p}$   $u = 0$ ，就得到了对  $\beta_j$  检验：

$$H_0: \beta_j = 0 \quad vs. \quad H_1: \beta_j \neq 0$$

因为此时  $A\hat{\beta} - u = \hat{\beta}_j$   $D = \{(X^T X)^{-1}\}_{[j,j]}$

于是，F-test 变为：

$$\text{若 } H_0: \beta_j = 0 \text{ 成立, } \frac{\hat{\beta}_j^2}{\{(X^T X)^{-1}\}_{[j,j]} \cdot SSE / (n-p)} \sim F(1, n-p)$$



① 可以判断 " $\beta_j \neq 0$ "

② 进一步，单变量可判断 " $\beta_j$  的正负"



由  $t^2(a) = F(1, a)$  可知：

$$\text{若 } H_0: \beta_j = 0 \text{ 成立, } \frac{\hat{\beta}_j}{\sqrt{\{(X^T X)^{-1}\}_{[j,j]} \cdot SSE / (n-p)}} \sim t(n-p)$$

## 6.3 拟合优度 Goodness of fit

(1) 决定系数: Coefficient of Determination

$$R^2 = \frac{SSR}{SST}$$

(2)  $y$  与所有自变量的复相关系数

$$R = \left( \frac{SSR}{SST} \right)^{\frac{1}{2}}$$

(3) 对整体自变量的检验:

利用  $\frac{SSR}{SSE}$  (等价的) 作检验, 假设只能对  $\beta_j (j \neq 1)$  整体检验:

$$H_0: \beta_j = 0 \quad (j=2, \dots, p), \text{ 反}$$

$$\frac{(n-p)/(p-1)}{R^2 - 1} = \frac{SSR/(p-1)}{SSE/(n-p)} \sim F(p-1, n-p)$$

Proof:  $\because \frac{(SSE_c - SSE) / (m)}{SSE / (n-p)} \sim F(m, n-p)$

取  $A = \begin{bmatrix} 0 & 1 & \cdots & 1 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} \in \mathbb{R}^{(p-1) \times p}$   $u=0 \Rightarrow \text{rank}(A)=m=p-1$ ,  $H_0: A\beta = u = 0$

$$\therefore \frac{(SSE_c - SSE) / (p-1)}{SSE / (n-p)} \sim F(p-1, n-p)$$

$$\therefore A\beta = 0 \Rightarrow \beta_1 \neq 0 \quad \beta_j = 0 \Rightarrow y_i = \beta_1 + \varepsilon_i \Rightarrow \text{预测 } \hat{y}_i = \bar{y}$$

无回归参数  $\Rightarrow SSR_c = 0 \Rightarrow SST = SSE_c$

$$\therefore \frac{SSR / (p-1)}{SSE / (n-p)} = \frac{(SST - SSE) / (p-1)}{SSE / (n-p)}$$

$$= \frac{(SSE_c - SSE) / (p-1)}{SSE / (n-p)} \sim F(p-1, n-p)$$

$$SST = \sum (y_i - \bar{y})^2 \quad SSR = \sum (\hat{y}_i - \bar{y})^2 \quad SSE = \sum (\hat{y}_i - y_i)^2$$

## 6.4 区间估计 Confidence Intervals

(1) 对单变量参数估计  $u = \hat{\beta}_j$

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{[(X^T X)^{-1}]_{jj} \cdot SSE / (n-p)}} \sim t(n-p)$$

$$P\left(\left|\frac{\hat{\beta}_j - \beta_j}{\sqrt{[(X^T X)^{-1}]_{jj} \cdot SSE / (n-p)}}\right| \leq t_{1-\alpha/2}\right) \geq 1-\alpha$$

(2)  $\beta_j$  的  $(1-\alpha)$  置信区间 CI

$$\left( \hat{\beta}_j - t_{1-\alpha/2}(n-p) \cdot \sqrt{\frac{[(X^T X)^{-1}]_{jj} \cdot SSE}{n-p}}, \quad \hat{\beta}_j + t_{1-\alpha/2}(n-p) \cdot \sqrt{\frac{[(X^T X)^{-1}]_{jj} \cdot SSE}{n-p}} \right)$$

## 7. 中心化 & 标准化 Centralization & Standardization

由  $X(y - X\hat{\beta}) = \sum_{i=1}^n x_i^T e_i = 0 \in \mathbb{R}^p$ , 取第一行有  $\sum_{i=1}^n (y_i - x_i^T \hat{\beta}) = 0$

$$\bar{y} = \bar{x}^T \hat{\beta} = \hat{\beta}_1 + \bar{x}_2 \cdot \hat{\beta}_2 + \cdots + \bar{x}_p \cdot \hat{\beta}_p$$

拟合一定过均值点,

(1) 中心化:

$$\hat{y}_i - \bar{y} = (x_{i1} - \bar{x}_1) \cdot \hat{\beta}_1 + \cdots + (x_{ip} - \bar{x}_p) \cdot \hat{\beta}_p \quad (i=1, 2, \dots, n)$$

(2) 标准化:

$$x_{ij}^* = \frac{x_{ij} - \bar{x}_j}{\hat{\sigma}_{x_j}} \quad i = 1, 2, \dots, n \quad j = 2, 3, \dots, p$$

$$y_i^* = \frac{y_i - \bar{y}}{\hat{\sigma}_y}$$

就有：

$$y_i^* = \beta_2^* x_{i2}^* + \beta_3^* x_{i3}^* + \dots + \beta_p^* x_{ip}^*$$

$$D = A(X^T X)^{-1} A^T$$

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

$$\hat{\beta}_C = \hat{\beta} - (X^T X)^{-1} A^T D^{-1} (A \hat{\beta} - u)$$

$$\|X(\hat{\beta}_C - \hat{\beta})\|^2 = \frac{(A \hat{\beta} - u)^T D^{-1} (A \hat{\beta} - u)}{\sigma} \sim \chi^2(m)$$



