

多重共线性 Multicollinearity

假设 Designed Matrix X "不再" 满秩:

$$\text{rank}(X) \approx p \quad X \in \mathbb{R}^{n \times p}$$

Assumption: ① 假设 Model 均满足 Gauss-Markov 条件

② 假设已中心化, 即

$\{y, x_1, \dots, x_p\}$ 中的向量的分量均值为 0, 方差为 1

$$\frac{1}{n} \sum_{j=1}^n y_j = 0 \quad \frac{1}{n} \sum_{j=1}^n (y_j - 0)^2 = 1$$

$$\frac{1}{n} \sum_{j=1}^n x_{ij} = 0 \quad \frac{1}{n} \sum_{j=1}^n (x_{ij} - 0)^2 = 1$$

③ β 不含截距项 $\beta \in \mathbb{R}^p$

一、定义 Definition

1. 完全多重共线性

若存在非 0 向量 $v \in \mathbb{R}^p$, 使设计矩阵 X 满足 $Xv = 0$, 即 X 列向量线性相关, 称为 (x_1, \dots, x_p) 完全多重共线性 Perfect Multicollinearity

2. 多重共线性

若存在非 0 向量 $v \in \mathbb{R}^p$, 使设计矩阵 X 满足 $Xv \approx 0$, 即 X 列向量线性相关, 称为 (x_1, \dots, x_p) 多重共线性 Multicollinearity

二、影响 Effect

1. 完全多重共线性

当自变量 $\{x_{(1)}, x_{(2)}, \dots, x_{(p)}\}$ 存在完全多重共线性时, 设计矩阵 X 不满秩, $\text{rank}(X) < p$ 则 $\text{rank}(X^T X) = \text{rank}(X) < p$, 即有 $X^T X$ 不可逆, 之后的 OLSE 均不可进行

2. 多重共线性

当自变量 $\{x_{(1)}, x_{(2)}, \dots, x_{(p)}\}$ 存在多重共线性时, 质量差, 因为方差 $\text{var}(v^T \hat{\beta})$ 的上界趋向 $+\infty$ (OLSE: 无偏)

$$\exists \lambda_{\min}\{X^T X\} \rightarrow 0$$

Proof^① $\text{cov}(\hat{\beta}) = \text{cov}(X^T X)^{-1} X^T y = (X^T X)^{-1} X^T \text{cov}(y) \cdot X (X^T X)^{-1} = \sigma^2 \cdot (X^T X)^{-1}$

$$\text{var}(v^T \hat{\beta}) = \text{cov}(v^T \hat{\beta}, v^T \hat{\beta})$$

$$= v^T \text{cov}(\hat{\beta}) v$$

$$= v^T \cdot \sigma^2 (X^T X)^{-1} \cdot v$$

$$\leq \sigma^2 \cdot \|v\|^2 \cdot \lambda_{\max}\{(X^T X)^{-1}\}$$

$$= \sigma^2 \cdot \|v\|^2 \cdot [\lambda_{\min}\{X^T X\}]^{-1}$$

$X^T X$ 存在接近 0 的特征根, 故 $\frac{1}{\lambda_{\min}\{X^T X\}} \rightarrow \infty$

Proof^② $\hat{\beta}$ 各分量方差加和 $\text{tr}\{\sigma^2 (X^T X)^{-1}\} = \sigma^2 \cdot \sum_{j=1}^p \lambda_j^{-1} \rightarrow \infty$

三、诊断 Diagnoses

1. 方差扩大因子法 Variance inflation factor (VIF)

因为已经标准化, 故 $\text{corr}(\hat{\beta}) = \sigma^2 (X^T X)^{-1} = (X^T X)^{-1}$, 记

$$C = (X^T X)^{-1}$$

称 C 的第 j 个对角元素为:

$$VIF_j = C_{[j,j]}$$

称 VIF_j 为自变量 $X_{(j)}$ 的 **方差扩大因子**, 由于 $\text{cov}(\hat{\beta}) = \sigma^2 C$, 故

$$\text{var}(\hat{\beta}_{[j]}) = \sigma^2 VIF_j$$

衡量标准:

① VIF_j 衡量 $\hat{\beta}_j$ 方差因多重共线性而扩大的程度

② **经验判断:** $VIF_j \geq 10$, 认为 $X_{(j)}$ 与其他有明显多重共线性

③ **检验整体:** $\frac{1}{p} \sum_{j=1}^p VIF_j \gg 1$, 认为整体有明显多重共线性

2. 特征根判定法: Eigenvalue-based

\exists 多重共线性 $\Leftrightarrow \lambda_{\min}\{X^T X\}$ 接近 0

经验判断:

考虑 $X^T X$ 的特征根 λ :

① $0 < \frac{\lambda_{\max}}{\lambda_{\min}} < 100$ 不存在多重共线性

② $100 < \frac{\lambda_{\max}}{\lambda_{\min}} < 10000$ 存在较强多重共线性

③ $\frac{\lambda_{\max}}{\lambda_{\min}} > 10000$ 存在严重多重共线性

3. 直观判断 Intuitive judgement

- 增加或删除某个自变量，或者改变某个观测值时，回归系数的估计发生较大变化；
- 定性分析认定的一些重要自变量在拟合结果中没有通过显著性检验；
- 某些自变量回归系数估计值的正负号与定性分析结果不符；
- 自变量间的相关系数较大；
- 某些重要自变量回归系数估计值的标准误差较大。