

回顾：多重共线性，即 $\lambda_{\min}(X^T X)$ 非常接近于 0

一、岭回归定义

Definition of Ridge Regression

1.1 调节参数平移

记 $k > 0$ 为调节参数 (tuning parameter)，我们把设计矩阵 $X^T X$ 平移 k 个单位后进行 OLS，于是得到 β 的岭回归估计

$$\hat{\beta}_k = (X^T X + k \cdot I)^{-1} \cdot X^T \cdot y$$

显然，原始 OLS 是 $k=0$ 时的特例： $\hat{\beta} = \hat{\beta}_0$

Lemma: $\lambda_{\min}(X^T X + k \cdot I) \geq k$

Proof: $\because X^T X$ 为实对称阵 $\Rightarrow X^T X = \Phi \Lambda \Phi^T$ 其中 Φ 为正交阵。

而 Λ 为对角阵。则有

$$X^T X + kI = \Phi \Lambda \Phi^T + kI = \Phi (\Lambda + kI) \Phi^T$$

于是有 $\lambda(X^T X + kI)$ 为 $\Lambda + kI$ 的对角元素

又注意到 $v^T X^T X v = \|Xv\|^2 \geq 0$ ，则有 $X^T X$ 半正定， Λ 的每个元素非负

$$\text{故 } \lambda(X^T X + kI) \geq 0 + k = k \quad \square$$

由 Lemma，我们可以保证 $(X^T X + kI)$ 避免多重共线性。

1.2 基于优化的定义

岭回归估计 $\hat{\beta}_k$ 也可以通过如下定义：

$$\hat{\beta}_k = \underset{b \in \mathbb{R}^p}{\operatorname{argmin}} \left\{ \|y - Xb\|^2 + k \cdot \|b\|^2 \right\}$$

本质为“惩罚回归”(penalized regression). 且采用了 L_2 范数惩罚项。

若 $Q(b) = \|y - Xb\|^2 + k \cdot \|b\|^2$, 则有

$$\frac{\partial Q}{\partial b} = 2X^T(y - Xb) + 2kb$$

$$\frac{\partial^2 Q}{\partial b^2} = 2X^T X + 2kI$$

令一阶导为0得 $\hat{\beta}_k = (X^T X + kI)^{-1} X^T y$ 与定义 1.1 等价

Proof: 由 Lemma 知 $X^T X + kI$ 的特征根 $\geq k > 0$, 故 $X^T X + kI$ 正定, 即

$\frac{\partial^2 Q}{\partial b^2} \geq 0$ 于是 $\hat{\beta}_k$ 确为最小值点,

1.3 基于 Lagrange 定义

岭回归也可以定义为有限制的优化问题: ($s \geq 0$)

$$\tilde{\beta}_s = \underset{b \in \mathbb{R}^p}{\operatorname{argmin}} \|y - Xb\|^2$$

$$\text{s.t. } \|b\|^2 \leq s$$

如上同样采用了 L_2 范数约束, 下面证明等价性:

Proof: 对 $\forall s \in [0, \infty]$, 都 $\exists k \in [0, \infty]$, 使 $\hat{\beta}_k = \tilde{\beta}_s$

(1) 若 $\text{rank}(X) < p$ OLS 不存在, 我们不讨论

(2) 若 $\text{rank}(X) = p$

① 若 $(X^T X)^{-1} X^T y = 0$, 即 OLS: $\hat{\beta} = 0$ 那么对 $\forall s$ $\|b\|^2 \leq s$ 无意义

此时 $\hat{\beta}_k = \tilde{\beta}_s = 0$ 平凡

② 若 $(X^T X)^{-1} X^T y \neq 0$, 由 Lagrange 乘子法:

$$L(b, u) = \|y - Xb\|^2 + u \cdot (s - \|b\|^2)$$

故求导知, $\tilde{\beta}_s$ 满足: $\|y - Xb\|^2 + u \cdot (\|b\|^2 - s) = 0$

$$-2X^T(y - X\tilde{\beta}_s) + u\tilde{\beta}_s = 0 \quad u \cdot (\|\tilde{\beta}_s\|^2 - s) = 0 \quad (1)$$

$$\|\tilde{\beta}_s\|^2 - s = 0 \quad X^T(X\tilde{\beta}_s - y) + u\tilde{\beta}_s = 0 \quad (2)$$

(a). 若 $s \geq \|\hat{\beta}\|^2 = \|(X^T X)^{-1} X^T y\|^2$, 则限制无意义

取 $k=0$ 有 $\hat{\beta}_k = \hat{\beta} = \tilde{\beta}_s$

(b) 若 $0 \leq s < \|(X^T X)^{-1} X^T y\|^2$

则 $u \neq 0$, 否则由(2) 有 $\|\tilde{\beta}_s\|^2 = \|(X^T X)^{-1} X^T y\|^2 > s$ 矛盾!

由(2) 知

$$\tilde{\beta}_s = (X^T X + u \cdot I)^{-1} X^T y \quad (3)$$

由(1) 知

$$s = \|\tilde{\beta}_s\|^2 = \|(X^T X + u \cdot I)^{-1} X^T y\|^2 \quad (4)$$

故对给定的 s , 由(4) 解出 u , 令 $k=u$ 有 $\hat{\beta}_k = \tilde{\beta}_s$ \square

($\because f(u) = \|(X^T X + u \cdot I)^{-1} X^T y\|^2$ 连续, 且值域与 s 取值重合, 一定有解 u)

1.4 基于 Bayesian 学派的定义

假设似然函数为

$$y|\beta \sim N(X\beta, I).$$

先验 (prior) 分布为

$$\beta \sim N(0, \tau^2 I)$$

其中 $\tau > 0$, 则后验 (posterior) 分布为

$$P(\beta|y) = \frac{P(\beta) \cdot P(y|\beta)}{P(y)}$$

$$\propto P(\beta) \cdot P(y|\beta)$$


$$\propto \exp\left\{-\frac{\|\beta\|^2}{2\tau^2}\right\} \cdot \exp\left\{-\frac{1}{2}\|y - X\beta\|^2\right\}$$

$$= \exp\left\{-\left(2\tau^2\right)^{-1} \|\beta\|^2 - \frac{1}{2}\|y - X\beta\|^2\right\}$$


故 β 的最大后验估计为

$$\hat{\beta}_\tau = \underset{b \in \mathbb{R}^p}{\operatorname{argmin}} \left\{ \|y - Xb\|^2 + \tau^2 \|b\|^2 \right\}$$

等价于之前定义, 取 $R = \tau^{-2}$ 即可



Lasso 回归 (可以压缩为 0)



Ridge 岭回归

二、岭回归性质

Properties of Ridge Regression

2.1 线性 Linearity

若认为调节参数 k 与 y 无关，则

$$\hat{\beta}_k = (X^T X + kI)^{-1} X^T y$$

是 y 的线性函数，

$$\begin{aligned}\hat{\beta}_k &= (X^T X + kI)^{-1} X^T y \\&= (X^T X + kI)^{-1} \cdot X^T X (X^T X)^{-1} \cdot X^T y \\&= (X^T X + kI)^{-1} X^T \cdot X \cdot (X^T X)^{-1} X^T y \\&= (X^T X + kI)^{-1} X^T X \hat{\beta}\end{aligned}$$

是 $\hat{\beta}$ 的线性函数

Tips: 实际 k 取值依赖于 y , 上面就不成立

2.2 有偏性 biasedness

$$E(\hat{\beta}_k) = (X^T X + kI)^{-1} \cdot X^T X \beta$$

若 $k > 0$, 则 $E(\hat{\beta}_k) \neq \beta$

2.3 估计值的 L₂ 范数减小 Shrinkage

若 $\hat{\beta} \neq 0$, $k > 0$ 则有

$$\|\hat{\beta}_k\| < \|\hat{\beta}\|$$

Tips: 但无法压缩至以正概率取 0, 但 LASSO 回归可以:

利用 L₁ 范数修正, 可以使 $\exists j \quad P(\hat{\beta}_{kj} = 0) > 0$

2.4 协方差减小 Shrinkage of Covariance

若 $k > 0$, 则 $\{\text{cov}(\hat{\beta}) - \text{cov}(\hat{\beta}_k)\}$ 正定

Proof: 见习题

Tips: 性质 2.3 和 2.4 说明, 岭回归对估计量进行了压缩(Shrinkage)

显然, 当 $k \rightarrow \infty$, $\hat{\beta}_k \rightarrow 0$

由 Chapter 4 Theorem 5:

$$\begin{aligned} E(\|\hat{\beta}\|^2) &= E(\hat{\beta}^T I \hat{\beta}) \\ &= E(\hat{\beta}^T) \cdot I \cdot E(\hat{\beta}) + \text{tr}\{I \cdot \text{cov}(\hat{\beta})\} \\ &= \|\beta\|^2 + \sigma^2 \sum_{j=1}^p \lambda_j^{-1} \end{aligned}$$

其中 $\lambda_1, \dots, \lambda_p$ 为 $X^T X$ 的特征值。这说明, $\lambda_{\min} \rightarrow 0$ 时,

OLS 的 L₂ 范数期望 $E(\|\hat{\beta}\|^2) \rightarrow \infty$.

2.5 均方误差 mean squared error, MSE

对于 β 的任意估计量 $\tilde{\beta}$, 定义其均方误差为:

$$MSE(\tilde{\beta}) = E(\|\tilde{\beta} - \beta\|^2)$$

则岭回归对均方误差的改进:

$$\exists R \text{ s.t. } MSE(\hat{\beta}_k) < MSE(\hat{\beta})$$

$$\text{即: } E(\|\hat{\beta}_k - \beta\|^2) < E(\|\hat{\beta} - \beta\|^2)$$

Lemma 1 对于 β 的任意估计量 $\tilde{\beta}$, 其 MSE 均满足:

$$MSE(\tilde{\beta}) = \text{tr}\{\text{cov}(\tilde{\beta})\} + \|E(\tilde{\beta}) - \beta\|^2$$

此外, 对于任意正交阵 $P \in \mathbb{R}^{P \times P}$, 有:

$$E\{P \cdot \|\tilde{\beta} - \beta\|^2\} = E(\|\tilde{\beta} - \beta\|^2)$$

利用 Lemma 1 对性质 2.5 证明:

由于 $X^T X$ 为实对称矩阵, 故 \exists 正交阵 $\Phi \in \mathbb{R}^{P \times P}$ 与对角阵 $\Lambda = \text{diag}(\lambda_i)$

其中 λ_i 为 $X^T X$ 的特征根, 有:

$$X^T X = \Phi \Lambda \Phi^T$$

$$\text{记 } Z = X \Phi \quad \alpha = \Phi^T \beta := (\alpha_{[1]}, \dots, \alpha_{[P]})^T \quad \hat{\alpha}_k = \Phi^T \hat{\beta}_k,$$

故由引理第 2 个恒等式, 只须证:

$$E(\|\hat{\alpha}_k - \alpha\|^2) < E(\|\hat{\alpha}_0 - \alpha\|^2)$$

分别计算 $\text{cov}(\hat{\alpha}_k)$, $E(\hat{\alpha}_k)$ 有:

$$\begin{aligned}
 \text{cov}(\hat{\alpha}_k) &= \text{cov}(\Phi^T \hat{\beta}_k) \\
 &= \Phi^T \cdot \text{cov}((X^T X + kI)^{-1} X^T y) \cdot \Phi \\
 &= \Phi^T \cdot (X^T X + kI)^{-1} X^T \cdot \text{cov}(y) \cdot X (X^T X + kI)^{-1} \Phi \\
 &= \sigma^2 \cdot \Phi^T \cdot \{ \Phi (\Lambda + kI) \Phi^T \}^{-1} X^T X \{ \Phi (\Lambda + kI) \Phi^T \}^{-1} \Phi \\
 &= \sigma^2 \cdot \Phi^T \cdot \Phi (\Lambda + kI)^{-1} \Phi^T X^T X \Phi (\Lambda + kI)^{-1} \Phi^T \Phi \\
 &= \sigma^2 (\Lambda + kI)^{-1} \Lambda (\Lambda + kI)^{-1} \quad \text{均为对角阵} \\
 &= \sigma^2 \text{diag}\left(\frac{\lambda_i}{(\lambda_i + k)^2}\right)
 \end{aligned}$$

$$\begin{aligned}
 E(\hat{\alpha}_k) &= E(\Phi^T \hat{\beta}_k) \\
 &= \Phi^T (X^T X + kI)^{-1} X^T E(y) \\
 &= \Phi^T (X^T X + kI)^{-1} X^T X \beta \\
 &= \Phi^T \Phi (\Lambda + kI)^{-1} \Phi^T \cdot (\Phi \Lambda \Phi^T) \cdot \beta \\
 &= (\Lambda + kI)^{-1} \Lambda \Phi^T \beta \\
 &= (\Lambda + kI)^{-1} \Lambda \alpha \quad \text{均为对角阵} \\
 &= \text{diag}\left(\frac{\lambda_i}{\lambda_i + k}\right) \cdot \alpha
 \end{aligned}$$

由引理可得 $MSE(\hat{\alpha}_k)$ 为

$$\begin{aligned}
 g(k) &= MSE(\hat{\alpha}_k) = E(\|\hat{\alpha}_k - \alpha\|^2) \\
 &= \text{tr}(\text{cov}(\hat{\alpha}_k)) + \|\bar{E}(\hat{\alpha}_k) - \alpha\|^2 \\
 &= \sigma^2 \sum_{i=1}^p \frac{\lambda_i}{(\lambda_i + k)^2} + k^2 \sum_{i=1}^p \frac{\alpha_{ii}^2}{(\lambda_i + k)^2} \in \mathbb{R}
 \end{aligned}$$

求导得:

$$\frac{dg}{dk} = -2\sigma^2 \cdot \sum_{i=1}^p \frac{\lambda_i}{(\lambda_i + k)^3} + 2k \sum_{i=1}^p \frac{\lambda_i \alpha_{ii}^2}{(\lambda_i + k)^3}$$

$$\therefore g'(0) = -2\sigma^2 \sum \frac{1}{\lambda_i^2} + 0 < 0 \quad \text{而 } g'(k) \text{ 连续, 故 } \exists k_0 > 0$$

使 $g'(k) < 0$ 对 $\forall k \in (0, k_0]$ 成立，于是：

对 $\forall k \in (0, k_0]$ 有 $g(k) < g(0)$

$$\text{即 } E(\|\hat{\alpha}_k - \alpha\|^2) < E(\|\hat{\alpha}_0 - \alpha\|^2) \quad \blacksquare$$

三、调节参数 k 的选取

Choice of the tuning parameter k

3.1 交叉验证 Cross Validation

对固定 $M \in \mathbb{N}_+$, $M \geq 2$. 将指标集合 $J = \{1, 2, \dots, n\}$ 分割为 M 个容量

相近的互斥子集 J_1, \dots, J_M .

对于 $m = 1, 2, \dots, M$. 记 $\hat{\beta}_k^{(-m)}$ 为在 $\{(y_i, x_i) : i \notin J_m\}$ 上训练的岭回
归估计值。

针对 k 的选取集 $K \subset [0, \infty)$, 取 k 为使如上表现最佳的:

$$\hat{k} = \underset{k \in K}{\operatorname{argmin}} \sum_{m=1}^M \sum_{i \in J_m} (y_i - x_i^\top \hat{\beta}_k^{(-m)})^2$$

Tip: Cross Validation 是最常用的方法

3.2 Hoerl-Kennard 公式

3.3 Mcdorand-Gararneau 法

3.4 双 R 公式

见讲义