

回顾：多重共线性，即 $\exists \lambda_{\min}(X^T X)$ 非常接近于 0

一、主成分分析 Principle Component Analysis

对原始线性模型：

$$E(y) = X\beta \quad \text{cov}(y) = \sigma^2 I$$

其中 $X \in \mathbb{R}^{n \times p}$ $\beta \in \mathbb{R}^p$

记 $X^T X = \Phi \Lambda \Phi^T$ ，其中 $\Phi = [\phi_1, \phi_2, \dots, \phi_p] \in \mathbb{R}^{p \times p}$ 为正交阵，而 $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_p)$ 满足 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$ 。令

$$Z = X\Phi \quad \alpha = \Phi^T \beta$$

于是有主成分分析下的模型：

$$E(y) = Z\alpha \quad \text{cov}(y) = \sigma^2 I$$

其中 Designed Matrix： $Z = (z_{(1)}, z_{(2)}, \dots, z_{(p)}) = (X\phi_1, X\phi_2, \dots, X\phi_p)$

我们称由 X 列向量线性组合的 $\{z_{(j)} : j=1, 2, \dots, p\}$ 为主成分。

其中对应 $X^T X$ 第 j 大的特征值 λ_j 的 $z_{(j)}$ 称为第 j 主成分。

如此，我们可对 $E(y) = Z\alpha$ 使用回归

Remark：若假设自变量已中心标准化，即 $1^T X = 0$

$\Rightarrow 1^T Z = 1^T X \Phi = 0$ ，即 Z 各列平均值 $\bar{z}_{(j)} = 0$

$$\Rightarrow \sum_{i=1}^n (z_{ij} - \bar{z}_{(j)})^2 = z_{(j)}^T z_{(j)} = \phi_j^T X^T X \phi_j = \phi_j^T \Phi \Lambda \Phi^T \phi_j = \lambda_j$$

说明: $X^T X$ 的特征值 λ_j 衡量了主成分 $z_{(j)}$ 的波动大小。若 λ_j 比较小, 可以考虑删去 $z_{(j)}$ 后进行回归

二. 参数估计

Parameters Estimation of PCA

将下列矩阵写成分块形式:

$$\Lambda = \text{diag}(\Lambda_1, \Lambda_2)$$

$$\alpha = (\alpha_1^T, \alpha_2^T)^T$$

$$Z = (Z_1, Z_2)$$

$$\Phi = (\Phi_1, \Phi_2)$$

其中: $\Lambda_1 \in \mathbb{R}^{r \times r}$ $\alpha_1 \in \mathbb{R}^r$ $Z_1 \in \mathbb{R}^{n \times r}$ $\Phi_1 \in \mathbb{R}^{p \times r}$

剔除后 $(p-r)$ 个非主成分, 得到 r 个主成分模型:

$$E(y) \approx Z_1 \alpha_1 \quad \text{cov}(y) = \sigma^2 I$$

直接使用 OLSE 得:

$$\hat{\alpha}_1 = (Z_1^T Z_1)^{-1} Z_1^T y$$

$$= (\Phi_1^T X^T X \Phi_1)^{-1} Z_1^T y = (\Phi_1^T \Phi \Lambda \Phi^T \Phi_1)^{-1} Z_1^T y$$

$$= \Lambda_1^{-1} Z_1^T y$$

认为 $\hat{\alpha}_2 = 0$, 于是得到 β 的主成分估计:

$$\bar{\beta} = \Phi (\hat{\alpha}_1^T, \hat{\alpha}_2^T)^T = \Phi_1 \Lambda_1^{-1} \Phi_1^T X^T y$$

$$\alpha = \Phi^T \beta \Rightarrow \bar{\beta} = \Phi \alpha = \Phi \begin{pmatrix} \alpha_1 \\ \alpha_2 \end{pmatrix} = \Phi_1 \alpha_1 + \Phi_2 \alpha_2 = \Phi_1 \Lambda_1^{-1} Z_1^T y$$

$$Z = (Z_1 \ Z_2) = X \Phi \\ = (X \Phi_1 \ X \Phi_2)$$

三、主成分估计的性质

Properties of PCA estimate

有偏，但减小了方差，一定条件下优化了 MSE

3.1. 有偏性

$$E(\bar{\beta}) = E(\Phi_1 \Lambda_1^{-1} Z_1^T y) = \Phi_1 \Lambda_1^{-1} Z_1^T \cdot Z_1 \alpha_1 \\ = \Phi_1 \alpha_1$$

$$E(\bar{\beta}) = \Phi_1 \alpha_1$$

若 $\alpha_2 \neq 0$ ，则 $E(\bar{\beta}) \neq \beta$

3.2. MSE 改进

$$\text{cov}(\bar{\beta}) = \text{cov}(\Phi_1 \Lambda_1^{-1} Z_1^T y) = \sigma^2 \Phi_1 \Lambda_1^{-1} Z_1^T Z_1 \Lambda_1^{-1} \Phi_1^T \\ = \sigma^2 \Phi_1 \Lambda_1^{-1} \Phi_1^T \\ \text{tr}(\Phi_1 \Lambda_1^{-1} \Phi_1^T) \\ = \text{tr}(\Lambda_1^{-1})$$

$$\text{若 } \|\alpha_2\|^2 < \sigma^2 \sum_{j=r+1}^p \lambda_j^{-1}$$

$$\text{则 } \text{MSE}(\bar{\beta}) < \text{MSE}(\hat{\beta})$$

$$\text{其中 } \hat{\beta} = (X^T X)^{-1} X^T y \\ \text{MSE}(\hat{\beta}) = \text{tr}\{\text{cov}(\hat{\beta})\} \\ = \text{tr}\{\text{cov}(X^T X)^{-1} X^T y\} = \text{tr}\{(X^T X)^{-1} X^T \cdot \sigma^2 I \cdot X (X^T X)^{-1}\} \\ = \text{tr}\{(X^T X)^{-1}\} \sigma^2 = \sigma^2 \text{tr}(\Lambda^{-1})$$

Remark: 由于 $\alpha_2 = \Phi_2^T \beta$ ，故条件 $\|\alpha_2\|^2 < \sigma^2 \sum_{j=r+1}^p \lambda_j^{-1}$ 可写作：

$$\|\frac{\alpha_2}{\sigma}\|^2 = (\frac{\beta}{\sigma})^T \Phi_2 \Phi_2^T (\frac{\beta}{\sigma}) < \text{tr}(\Lambda_2^{-1})$$

直观地理解，PCA 在 MSE 上优于 OLS 的 条件：

(a). 固定 β 和 σ^2 ，矩阵 $X^T X$ 的前 $(p-r)$ 个特征值足够小

(b). 固定 Λ_2 和 Φ_2 (即固定 $X^T X$)，模长 $\|\frac{\beta}{\sigma}\|$ 足够小，即模型信噪比

$\beta^T X^T X \beta / \sigma^2$ 足够低，自身波动太大

四. 主成分分析应用

Implementation of PCA

4.1. 预设贡献率

使 $\frac{\sum_{j=1}^r \lambda_j}{\sum_{i=1}^p \lambda_i} > \text{rate 的 } r$

rate 为预设水平, 如 75%, 80% ...

4.2. 可解释性

$Z = X\Phi$, 为 X 的线性组合, 须解释其含义。

\Rightarrow 转化回原本 $X\beta$ 形式。

补:

$$\begin{aligned} \text{diag}(\lambda_1, \lambda_2) = \Lambda &= \Phi^T \Phi \Lambda \Phi^T \Phi = \Phi^T X^T X \Phi = Z^T Z = \begin{bmatrix} Z_1^T Z_1 & Z_1^T Z_2 \\ Z_2^T Z_1 & Z_2^T Z_2 \end{bmatrix} \\ &= \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} \end{aligned}$$