

具体的模型选择方法

四. 模型选择方法

Some popular model selection approaches

合格的模型选择方法应满足一些性质, 如 **选择一致性 (selection consistency)**

假设 $\exists A_0 \subset \mathcal{P} = \{2, 3, \dots, p\}$ (去除第一个截距项), 使对 $\forall j \in A_0$ 有 $\beta_{[j]} \neq 0$

而 $\forall j \notin A_0$ 有 $\beta_{[j]} = 0$

合格的模型选择方法应当基于数据产生一个 $\hat{A}_n \subset \{2, 3, \dots, p\}$ 满足

$$\lim_{n \rightarrow \infty} P(\hat{A}_n = A_0) = 1$$

一. 全子集回归 All-subset Regression

考虑 $\mathcal{P} = \{2, 3, \dots, p\}$ 的所有非空子集, 使用标准 $M(\cdot)$ 选择:

$$\hat{A}_n = \operatorname{argmin}_{A \in \mathcal{P}} M(A)$$

下面描述一些记号:

(1) 记 x_{iA} 为 $x_i = (x_{i1}, \dots, x_{ip})^T$ 的子向量, 只含 x_i 中 $\{x_{ij} : j \in \{1\} \cup A\}$ 的分量

(2) 记 $\hat{\beta}_A$ 表示数据集 $\{(y_i, x_{iA}) : i \in \mathcal{N}\}$ 的 OLSE $\mathcal{N} = \{1, 2, \dots, n\}$

之后, 便要决定利用如何的标准 $M(\cdot)$

1.1 预测误差 prediction error

对于 $K \geq 2$, 划分 $N = \{1, 2, \dots, n\}$ 为 K 个互斥子集 N_1, \dots, N_K

对于 $k = 1, 2, \dots, K$, 记 $\hat{\beta}_A^{(-k)}$ 为使用 $\{(y_i, x_{iA}) : i \notin N_k\}$ 估计出的 OLSE, 则有:

$$M(A) = \sum_{k=1}^K \sum_{i \in N_k} (y_i - x_{iA}^T \cdot \hat{\beta}_A^{(-k)})^2$$

这便是交叉验证 (cross validation) 策略, 同样它不限于线性模型:

$$M(A) = \sum_{k=1}^K \sum_{i \in N_k} (y_i - \hat{g}_A^{(-k)}(x_{iA}))^2$$

1.2 调整样本决定系数 Adjusted R^2

若以 R^2 作为 $M(\cdot)$, 则对于 $A_1 \subset A_2$, 必然有 $M(A_1) \leq M(A_2)$

故要对自变量个数施加惩罚

令 $R^2(A)$ 为使用 $\{(y_i, x_{iA}) : i \in N\}$ 计算出的 R^2 , 调整为:

$$R_a^2(A) = 1 - \frac{(n-1) \cdot (1 - R^2(A))}{n - |A| - 1} = 1 - \frac{(n-1) \cdot SSE_A}{(n - |A| - 1) \cdot SST}$$

$$= 1 - \frac{(n-1) \left(1 - \frac{SST - SSE_A}{SST}\right)}{n - |A| - 1} = 1 - \frac{(n-1) SSE_A}{(n - |A| - 1) SST}$$

其中:

$$SSE_A = \sum_{i=1}^n (y_i - x_{iA}^T \cdot \hat{\beta}_A)^2$$

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2$$

Tips: $\Rightarrow SSE_A \downarrow \Rightarrow R_a^2(A) \uparrow$
 $\Rightarrow |A| \uparrow \Rightarrow R_a^2(A) \downarrow$

故可将 $M(A) = -R_a^2(A)$ 作为标准

1.3 赤池信息量 Akaike information criterion, AIC

AIC 是基于 Likelihood 函数值的选择标准。

Definition AIC 定义: 假设希望基于数据 Z 估计参数 $\theta \in \mathbb{R}^d$
而 Z 的似然函数为 $L(Z; \theta)$, 由此得到 MLE 为 $\hat{\theta}$, 则 AIC 为:

$$AIC = -2 \log L(Z; \hat{\theta}) + 2d$$

以上 AIC 由 2 部分组成: 第一部分表示模型拟合的好坏, $L(Z; \hat{\theta})$ 越大, 拟合越好; 第二部分是对模型复杂的惩罚。

在正态假设下, 基于 $\{(y_i, x_{iA}) : i \in N\}$ 的选模型 A 的参数 MLE

分别为 OLSE: $\hat{\beta}_A$ $\hat{\sigma}_A^2 = \frac{SSE_A}{n}$ 代入 $L(Z; \hat{\theta})$ 并去除无关项, 得

$$AIC(A) = n \log SSE_A + 2 \cdot |A|$$

特别地: $d = |A| + 2$ ($2, \dots, p$ + 截距 + $\hat{\sigma}_A^2$)

故最小化 $M(A) = AIC(A)$

1.4 C_p 统计量 C_p -Statistic

若 A 正确, 则 $x_{iA}^T \hat{\beta}_A$ 可视为 $E(y_i) = x_i^T \beta$ 的估计 ($i \in \mathcal{N}$)

而估计偏差平方和与随机误差方差 的比值为:

$$T_p(A) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_{iA}^T \hat{\beta}_A - x_i^T \beta)^2$$

可以证明:

$$E\{T_p(A)\} = \frac{E(SSE_A)}{\sigma^2} - n + 2(|A| + 1)$$

略去无关的项得 C_p 统计量

$$C_p(A) = \frac{SSE_A}{\hat{\sigma}^2} + 2|A|$$

其中 $\hat{\sigma}^2$ 为全模型 σ^2 的无偏估计:

$$\hat{\sigma}^2 = \frac{1}{n-p} \sum_{i=1}^n (y_i - x_i^T \hat{\beta})^2$$

故选择最小化 $M(A) = C_p(A)$

Tips. 由定理 3, 若 A 正确, 有 $\beta_{[j]} = 0 \quad \forall j \notin A$, 则

$$E(SSE_A) = (n - |A| - 1)\sigma^2$$

结合 $E(T_p(A))$ 知

$$E\{T_p(A)\} = |A| + 1$$

故

$$\begin{aligned}M(A) &= |SSE_A / \hat{\sigma}^2 - n + 2(|A| + 1) - (|A| + 1)| \\&= |SSE_A / \hat{\sigma}^2 - n + |A| + 1|\end{aligned}$$

也是合适的

二、逐步回归 Stepwise Regression